Pipeline Computacional para Análise de Assinaturas Harmônicas e Inter-harmônicas em Sistemas Trifásicos

Resumo visual dos 13 módulos construídos: da importação do Excel bruto até classificação, previsão e desagregação de cargas. Cada gráfico usa os resultados reais gerados nos notebooks executados contra o arquivo `BANCO_DADOS_CONSOLIDADO.xlsx` (19.501 aquisições × 2 planilhas, 17 condições experimentais).

Pipeline construído

13 módulos em 3 fases — cada uma depende apenas da anterior.

FUNDAÇÃO (1–4)

1 Importação · 2 Validação · 3 Organização (long/matrix/tensor) · 4 Normalização

ANÁLISE (5–8)

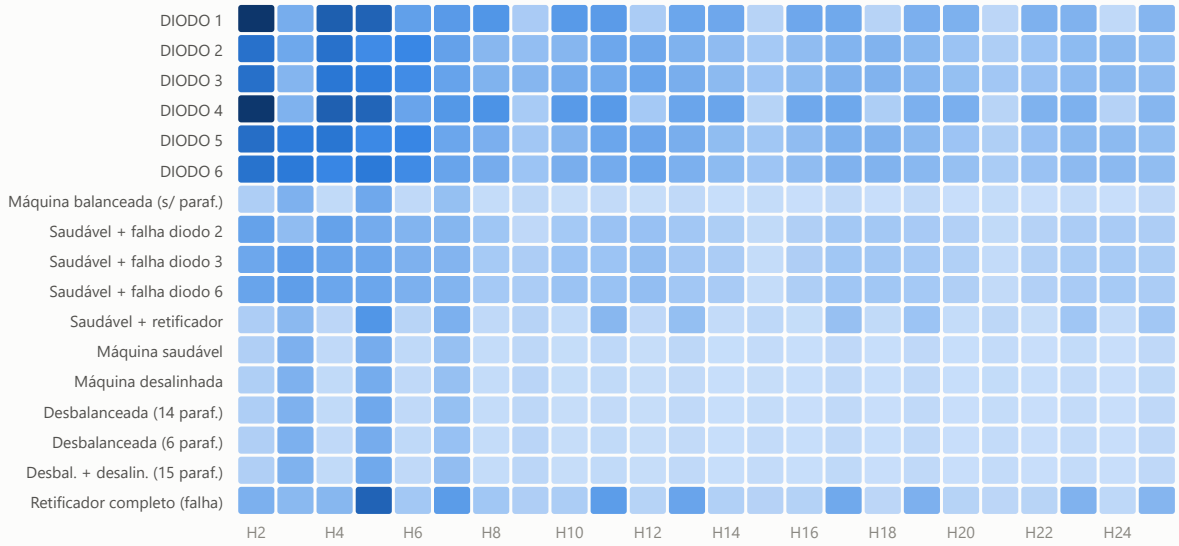
5 Visualização · 6 Estatística (FDR) · 7 Sensibilidade (SHAP) · 8 Seleção de atributos

MODELAGEM (9–13)

9 Modelos clássicos · 10 Janelamento · 11 Redes neurais · 12 Desagregação · 13 Predição

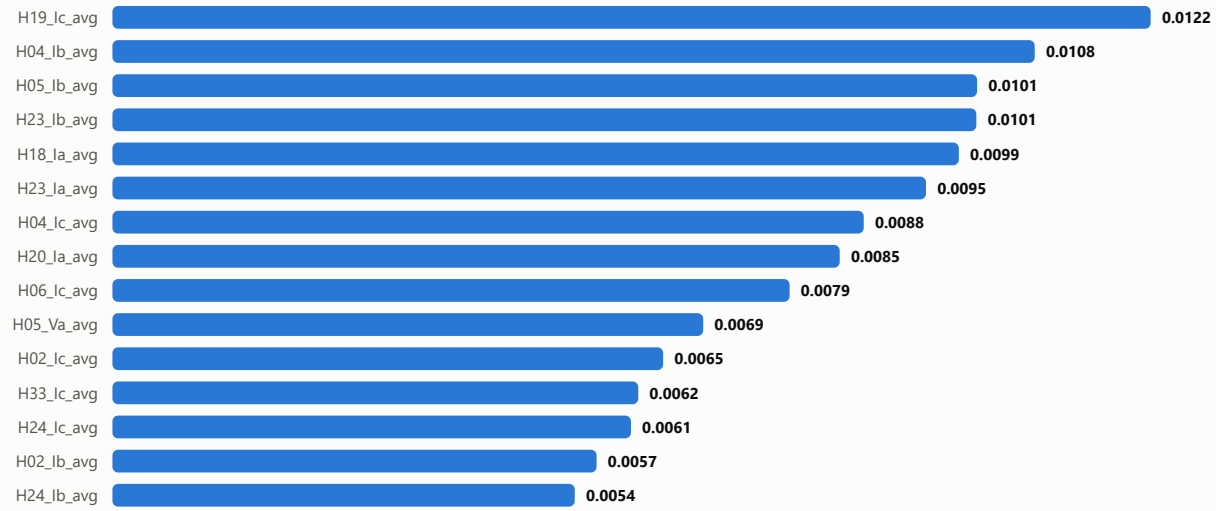
A assinatura harmônica de corrente (Ia, avg) — as 17 condições lado a lado

H2–H25 (H1/fundamental omitido — é sempre ≈100% por definição e não carrega informação diagnóstica). Cores mais escuras = maior amplitude. As 6 condições de falha de diodo/retificador dominam a escala; as 10 condições só-mecânicas ficam quase uniformemente claras por comparação — essa é, em si, a principal conclusão visual do dataset.



O que mais pesa na decisão do modelo (SHAP, Random Forest)

Top 15 features por importância média |SHAP| — harmônicos de corrente de baixa/média ordem (H2–H24) dominam; nenhuma feature de tensão aparece antes da 10ª posição.



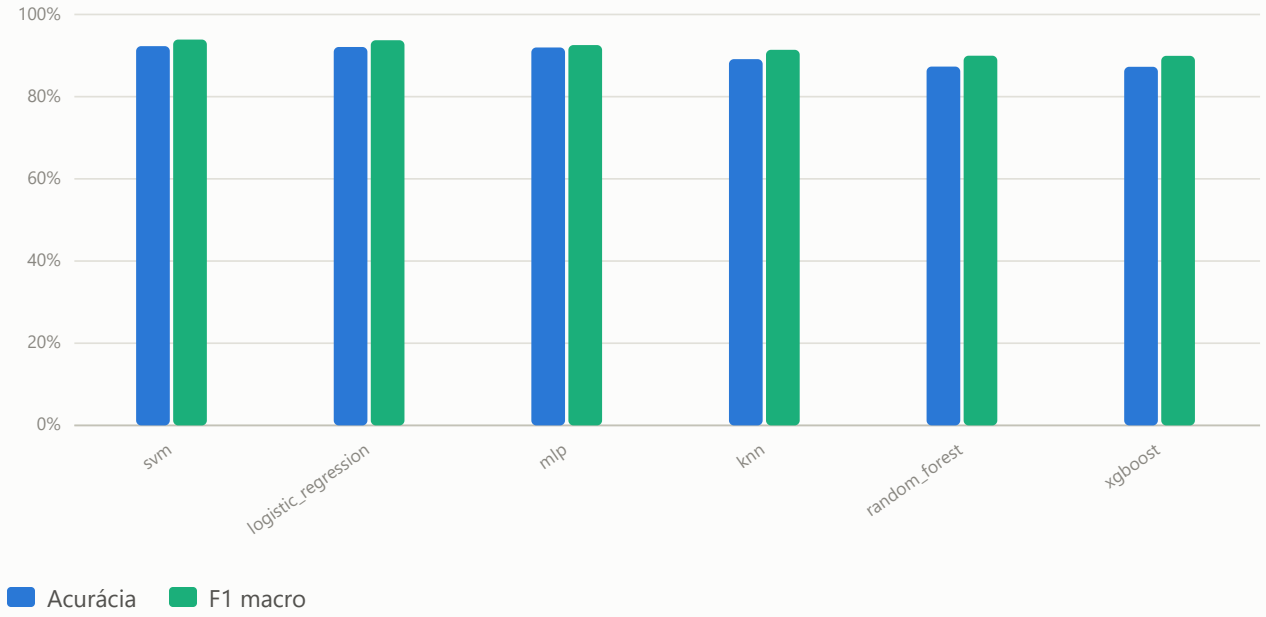
100%
canais estatisticamente significativos (ANOVA + FDR)

294
canais testados (família H, avg)

Com ~20 mil amostras, quase qualquer diferença real vira "significativa" — por isso o módulo de sensibilidade (Cohen's d / Cliff's delta / SHAP) é o que realmente separa sinal de ruído, não o p-valor sozinho.

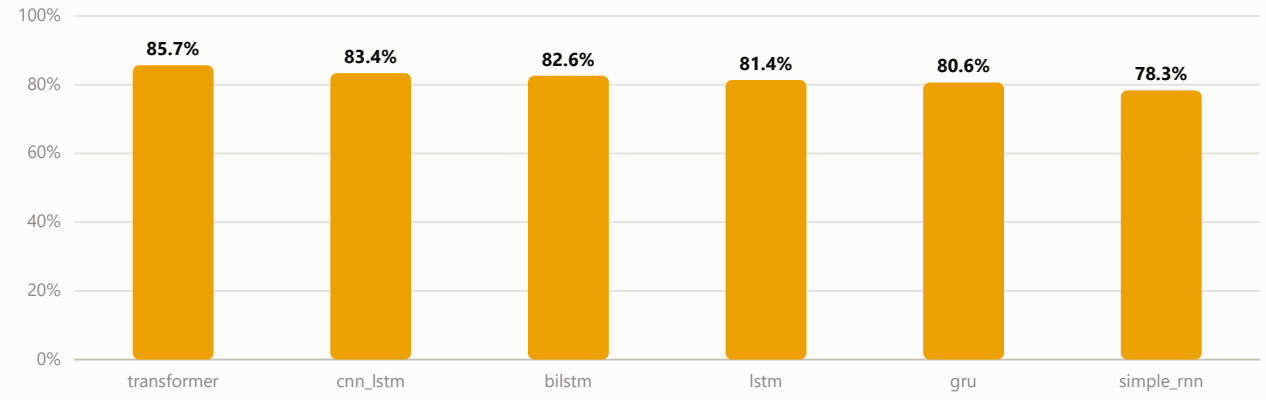
Classificação do tipo de falha — 6 modelos clássicos comparados

40 features selecionadas automaticamente (módulo 8), 17 classes, split 70/30.



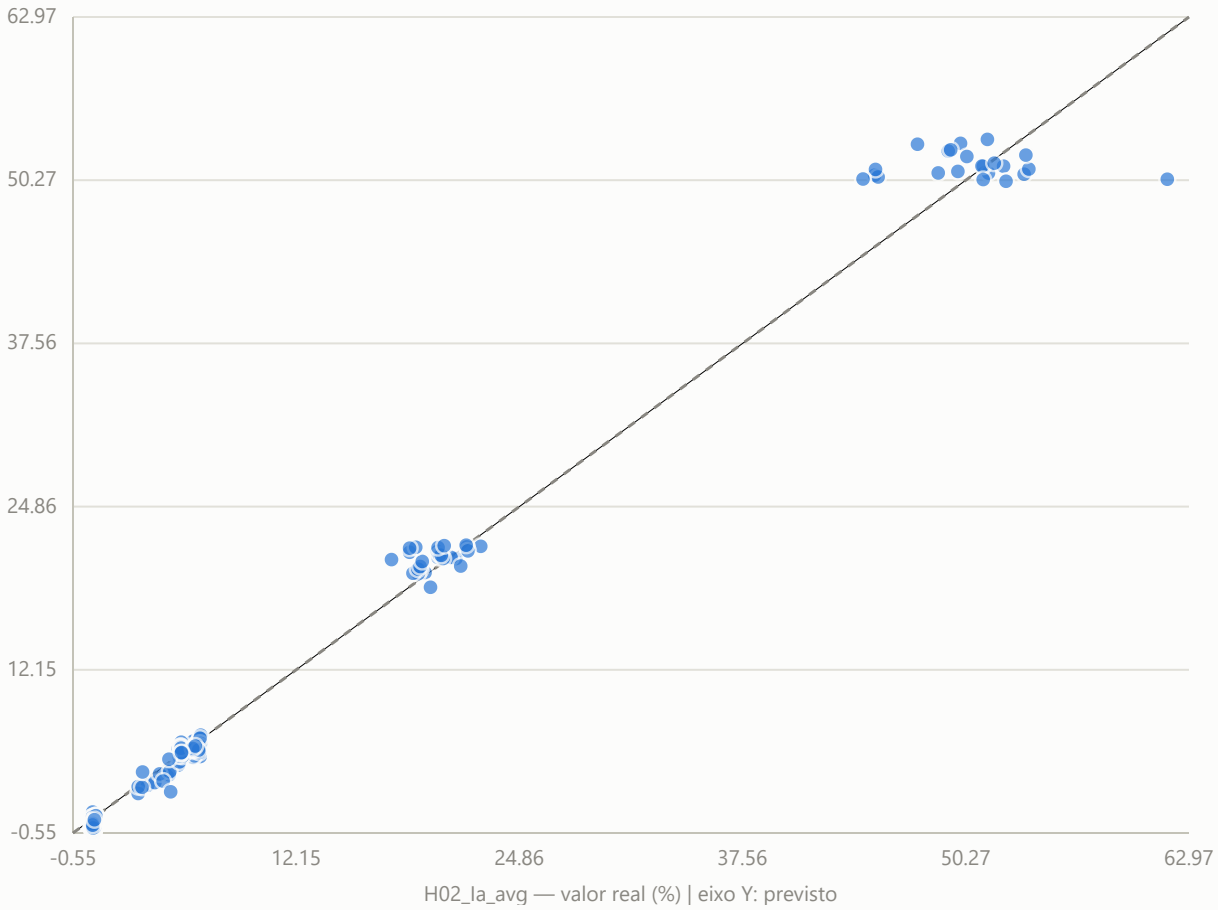
Classificação com contexto temporal — 6 arquiteturas de rede neural

Janelas de 8 aquisições consecutivas, 20 features, poucas épocas (baseline rápido — ajuste de hiperparâmetros disponível via módulo 11).



Previsão da assinatura futura (H02 Ia avg, 1 passo à frente)

BiLSTM prevendo o próximo valor a partir de uma janela de 8 leituras anteriores — cada ponto é uma janela de validação nunca vista no treino.

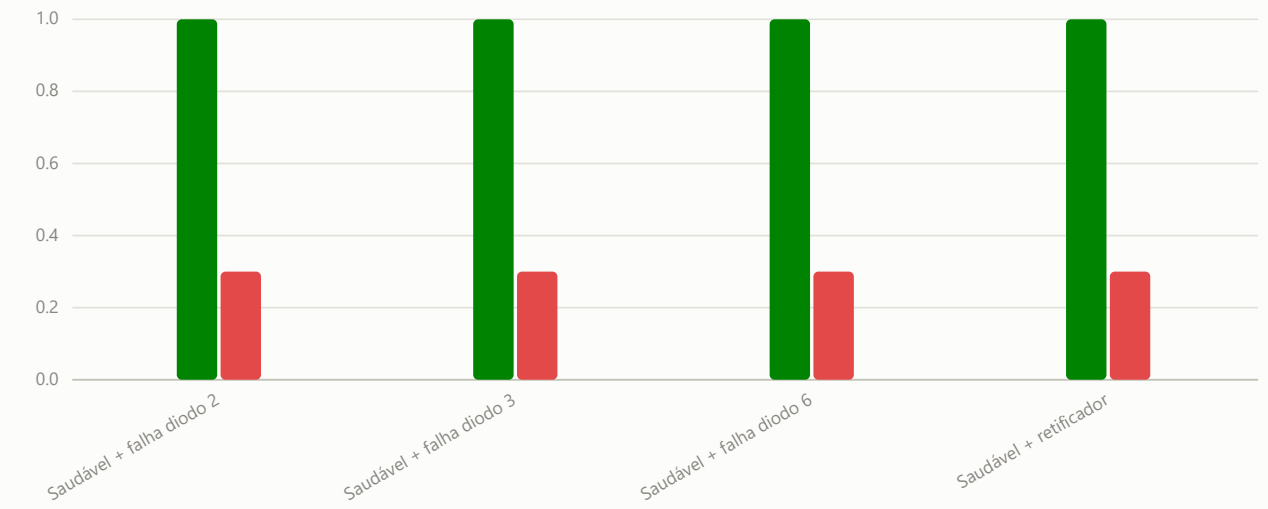


0.996
correlação real × previsto

0.104
MAE normalizado

Desagregação: separando máquina e falha do sinal combinado

Validação leave-one-condição-out (só 4 combinações existem no dataset).



LEITURA CORRETA DESTE GRÁFICO

O alvo **máquina** (R^2=1,0) é constante nas 4 combinações — todas usam a mesma condição de máquina saudável como base — então esse R^2 é um artefato da falta de variação, não prova de separação real. O alvo **defeito** (R^2≈0,3) é o que de fato testa se o modelo generaliza para uma combinação nunca vista.

Conclusões da análise

- **As falhas de diodo/retificador têm assinatura própria e forte** nos harmônicos de corrente de baixa ordem (H2–H7), com amplitudes 5–50× maiores que a máquina saudável — consistente com a teoria de retificação assimétrica (diodo aberto/removido introduz componentes pares e distorce a forma de onda de meio-ciclo).
- **Corrente domina sobre tensão** como canal diagnóstico: nas 40 features mais discriminativas, tensão só aparece a partir da 10ª posição no ranking SHAP — physicamente esperado, já que o defeito está no caminho de corrente (diodos/retificador), não na fonte de tensão.
- **Poucas features bastam**: 40 features (de ~300 candidatas) já dão 87–93% de acurácia com modelos clássicos simples — um sinal de que o diagnóstico pode rodar em hardware leve, sem precisar da tensão espectral completa.
- **Contexto temporal ajuda, mas modestamente**: as redes recorrentes com janela de 8 leituras (78–86%) não superam claramente os modelos clássicos sem contexto temporal (87–93%) neste baseline rápido — sugere que, para diagnóstico do tipo de falha, a assinatura instantânea já é quase suficiente; o valor do contexto temporal provavelmente aparece mais na previsão da assinatura futura (onde a correlação real×previsto foi de 0,996) do que na classificação.
- **Desagregação é viável em princípio** (R^2≈0,3 no defeito, com apenas 3 exemplos de treino por fold) — o suficiente para justificar coletar mais combinações máquina+defeito antes de escalar essa linha.

Limitações que os dados impõem — não o modelo

TEMPO RESTANTE ATÉ A FALHA (RUL)

Cada rótulo é uma sessão estacionária de ~4-6h com a falha já configurada desde o início — não há trajetória contínua de degradação com um evento de falha registrado. Sem isso, não existe alvo para supervisionar um modelo de RUL. Para viabilizar essa linha no futuro seria necessário um ensaio contínuo em que a falha se desenvolve progressivamente, com o instante de falha registrado.

DESAGREGAÇÃO COM N PEQUENO

Só 4 condições combinadas existem no dataset, todas com a mesma máquina-base — os números de desagregação acima são prova de conceito, não uma validação estatisticamente robusta.

Fonte: BANCO_DADOS_CONSOLIDADO.xlsx → pacote harmonic_signatures (módulos 1–13). Todos os números vêm de execuções reais registradas em notebooks/01–08.