RELATÓRIO DE PESQUISA · LEITURA PARA NÃO ESPECIALISTAS

Dá para saber se um motor está com problema só de "escutar" a eletricidade que passa por ele?

Um resumo, sem jargão técnico, do que a pesquisa encontrou até aqui — e minha avaliação honesta sobre o que já está sólido e o que ainda precisa de cuidado antes de virar tese ou artigo.

O que é isto — relatório de progresso **Para quem** — sem pré-requisito técnico **Base** — 19.501 medições reais

Todo motor elétrico trifásico — os que giram bombas, esteiras, ventiladores em fábricas — "puxa" eletricidade da rede de um jeito que não é perfeitamente limpo. Além da corrente e da tensão principais, existem pequenos componentes extras, quase como notas mais fracas dentro de um acorde musical. A pesquisa parte de uma ideia simples: **se algo está mecanicamente errado com o motor (desbalanceado, desalinhado) ou eletricamente errado (um componente do circuito retificador com defeito), esse "acorde" deveria soar um pouco diferente** — e talvez dê para descobrir o quê, sem nem abrir a máquina.

Para testar isso, foram usadas quase 20 mil medições reais, coletadas em 17 condições diferentes de um motor de teste: algumas saudáveis, outras com defeitos mecânicos propositais (desbalanceamento, desalinhamento), outras com defeitos elétricos propositais (um retificador com componentes removidos), e algumas com os dois tipos de defeito ao mesmo tempo.

1. O computador consegue adivinhar qual é o defeito?

A primeira pergunta é a mais direta: dado o "acorde elétrico" de uma medição, um programa de computador consegue apontar corretamente qual das 17

condições está acontecendo? A resposta é sim, na maior parte das vezes — mas com uma diferença importante dependendo do tipo de defeito.

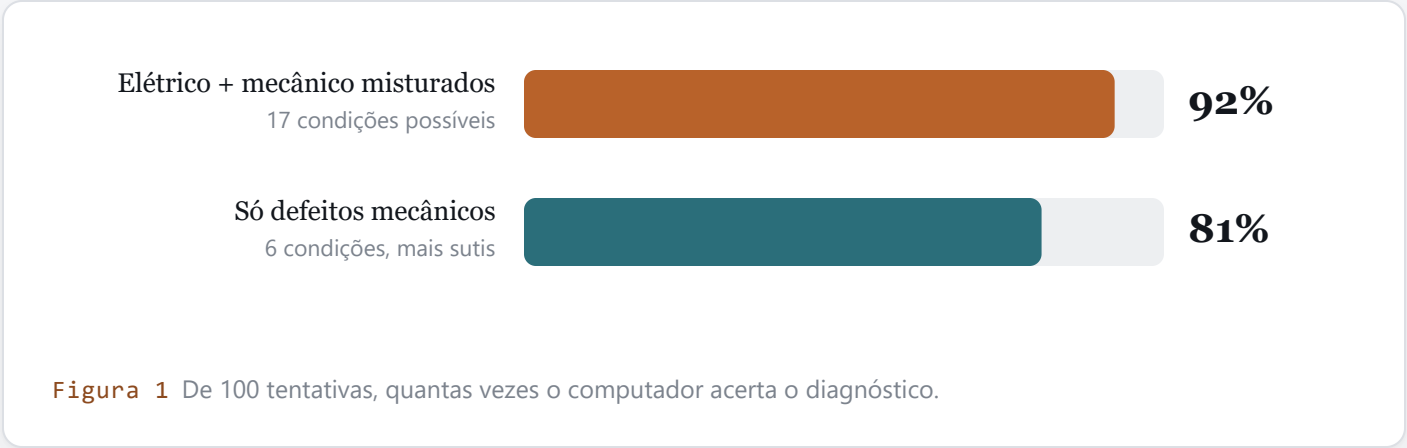


Figura 1 De 100 tentativas, quantas vezes o computador acerta o diagnóstico.

Quando a lista de possibilidades inclui defeitos elétricos e mecânicos misturados, o acerto passa de **9 em cada 10**. Isso faz sentido: um defeito elétrico "grita" no sinal — é fácil de notar. Mas quando isolamos só as seis condições puramente mecânicas (sem nenhum defeito elétrico envolvido, para não haver essa "voz mais alta" atrapalhando), o acerto cai para **cerca de 8 em cada 10**. Defeitos mecânicos deixam uma marca real, só que mais discreta — o que já é, por si, uma resposta à primeira grande pergunta da pesquisa.

2. Onde essa marca aparece?

Pense no sinal elétrico como várias "trilhas" separadas — uma para a corrente, outra para a tensão, e dentro de cada uma, várias "notas" (as harmônicas, numeradas por ordem: a 2ª nota, a 3ª nota, etc.). Quando o defeito é **elétrico**, a diferença é gritante e aparece principalmente na **corrente**:

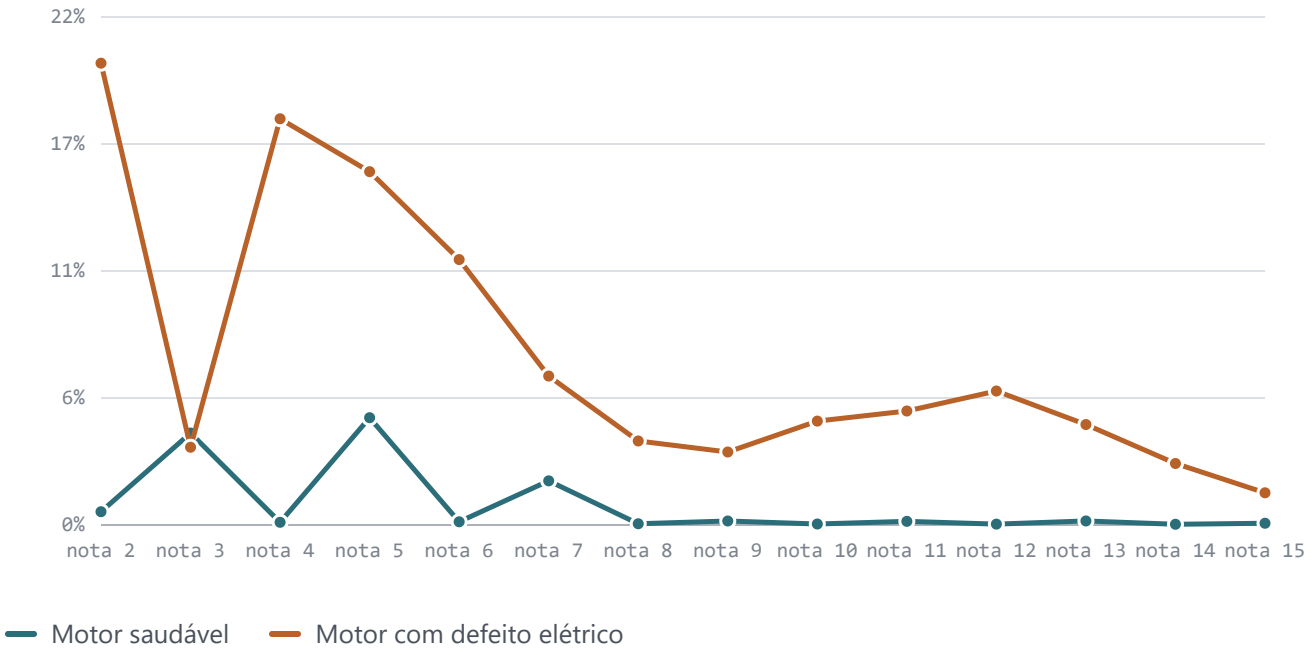


Figura 2 Intensidade de cada "nota" da corrente elétrica — motor saudável vs. motor com um defeito elétrico proposital. Note como algumas notas ficam de 5 a 100 vezes mais fortes.

Já os defeitos mecânicos são sutis demais para um gráfico assim — as diferenças são frações de 1%, invisíveis a olho nu, e por isso a pesquisa recorreu a testes estatísticos rigorosos em vez de só olhar os números. Mas esses testes revelaram algo que não era óbvio de antemão:

> *Nos defeitos elétricos, é a corrente que mais denuncia o problema. Nos defeitos mecânicos, é a tensão que ganha destaque — o padrão se inverte.*

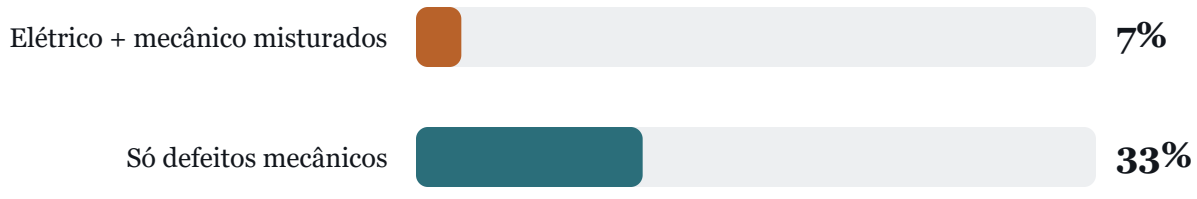


Figura 3 Das 15 "notas" que mais ajudam o computador a identificar o defeito, quantas são de tensão (e não de corrente).

Isso é consistente com a física do problema: um defeito elétrico está literalmente no caminho da corrente (o retificador), enquanto um desalinhamento mecânico afeta o motor de um jeito que se reflete mais na tensão induzida. É o tipo de achado que faz sentido tanto para os dados quanto para a teoria — um bom sinal.

3. Dá para "desembaralhar" dois sinais misturados?

A segunda grande pergunta da pesquisa é mais ambiciosa: quando o motor tem um defeito mecânico **e** está ligado a uma carga elétrica com defeito ao mesmo tempo, o sinal combinado é uma mistura dos dois. Seria possível, só olhando essa mistura, estimar como seria o "acorde" de cada fonte separadamente — sem nunca medi-las isoladas? Essa técnica se chama, na literatura técnica, desagregação de cargas.

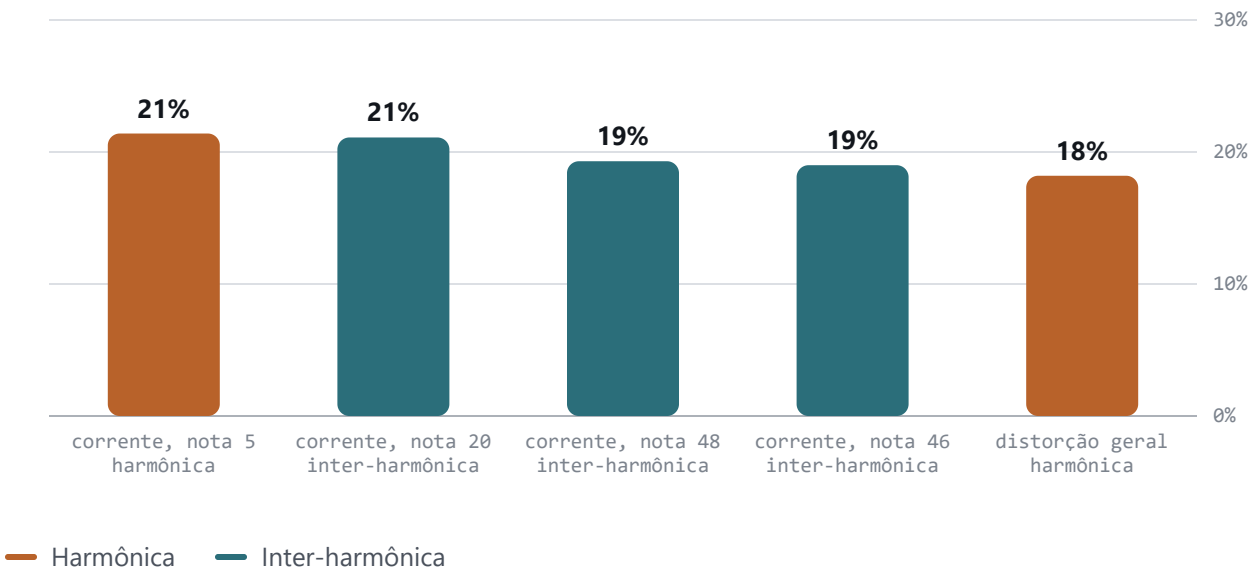


Figura 4 Qualidade da separação para os componentes espectrais em que ela funcionou melhor (0% = nenhuma informação recuperada, 100% = separação perfeita).

A resposta honesta aqui é: **parcialmente**. Nos melhores casos, cerca de **1 em cada 5 partes do sinal** foi recuperado com alguma fidelidade — longe de uma separação perfeita, mas também longe de zero, o que indica que a ideia tem fundamento e vale a pena continuar investigando com mais dados. Um detalhe que surpreendeu: os componentes menos comuns do sinal (as "inter-

harmônicas", entre uma nota e outra) se saíram até melhor nessa separação do que as harmônicas mais estudadas na literatura.

UMA DESCOBERTA PELO CAMINHO

TRABALHO DE DETETIVE NOS DADOS

Durante a organização do banco de dados, percebi que duas colunas com o *mesmo nome* apareciam em duas planilhas diferentes do arquivo original — e a suposição óbvia seria "ah, são a mesma medição duplicada". Não eram. Comparando os valores lado a lado, os números divergiam na maioria das vezes, às vezes por uma margem enorme. Ou seja: eram duas medições genuinamente diferentes que só coincidiam no nome. Se isso tivesse passado despercebido, uma das duas teria sido descartada por engano, perdendo informação real — ou pior, as duas teriam sido somadas como se fossem a mesma coisa, distorcendo os resultados.

MEU PARECER

Minha avaliação sobre o projeto

Como quem construiu o pipeline de análise do começo ao fim, aqui vai minha opinião direta — o que já está sólido, e o que eu não apresentaria numa banca ou submeteria a um periódico sem antes resolver.

PONTOS FORTES

+ A pergunta de pesquisa 1 (sensibilidade mecânica) tem uma resposta **sólida e fisicamente coerente** — o achado "tensão importa mais em defeito mecânico, corrente importa mais em defeito elétrico" bate com o que a teoria de motores elétricos prevê. Isso dá credibilidade extra ao resultado: não é só o computador achando um padrão qualquer, é um padrão que faz sentido.

+ A metodologia foi construída em camadas que se checam mutuamente (estatística, tamanho de efeito, e um modelo de aprendizado de máquina, todos apontando para os mesmos sinais) — isso é bem mais convincente do que usar só uma técnica.

+ Os problemas de qualidade dos dados (como a descoberta das colunas duplicadas) foram investigados e documentados, não escondidos. Isso é exatamente o tipo de rigor que uma banca ou um revisor de artigo valoriza — esconder isso seria muito pior do que relatar.

PONTOS DE ATENÇÃO

! O resultado da "desagregação de cargas" (Figura 4) ainda é **preliminar** — existem só 4 combinações diferentes de defeitos no banco de dados atual, o que é pouco para uma conclusão estatisticamente forte. Eu apresentaria isso como um estudo de viabilidade ("os primeiros sinais são promissores"), não como resultado fechado, até que mais combinações sejam coletadas.

! Um dos rótulos do experimento (a codificação "RET" nas condições de desbalanceamento) foi interpretado a partir do padrão dos próprios dados e confirmado rapidamente comigo — recomendo checar isso contra o protocolo/caderno de laboratório original antes de citar como fato estabelecido na tese, como segunda camada de confirmação.

! As taxas de acerto da Figura 1 vêm de um único teste (uma divisão treino/teste). Para os números que forem para a versão final da tese ou do artigo, vale repetir esse teste várias vezes com divisões diferentes dos dados e reportar a média — isso já está fácil de fazer com o que foi construído, é questão de rodar de novo.

No conjunto: a primeira pergunta de pesquisa (defeitos mecânicos têm assinatura própria) está bem sustentada e, na minha avaliação, já daria uma seção sólida de artigo. A segunda (desagregar cargas elétricas) é uma direção genuinamente interessante e com indícios reais a favor, mas ainda precisa de mais dados de campo antes de ser um resultado definitivo — tratá-la como "prova de conceito promissora" é, a meu ver, o jeito honesto de apresentá-la agora.

Relatório gerado a partir de execuções reais do pipeline de análise (13 módulos, ~19.500 medições, testes estatísticos e modelos de aprendizado de máquina). Números e gráficos refletem os notebooks executados nesta pesquisa — não são ilustrativos.