RELATÓRIO TÉCNICO · VERSÃO DE PROGRESSO

Sensibilidade de assinaturas harmônicas e inter-harmônicas a falhas mecânicas e desagregação de cargas elétricas em sistemas trifásicos

Metodologia, construção do sistema de análise e resultados obtidos sobre a base de dados experimental (19.501 aquisições, 17 condições).

BASE DE DADOS	BANCO_DADOS_CONSOLIDADO.xlsx — 19.501 aquisições × 2 planilhas (HARMÔNICAS, INTERHARMÔNICAS)
PIPELINE	`harmonic_signatures` — 13 módulos, Python 3.11, 107 testes automatizados
ESCOPO	Fundação e organização de dados · análise estatística e de sensibilidade · modelos clássicos e redes neurais · desagregação de cargas (NILM) · predição

RESUMO

Investigou-se se assinaturas espectrais harmônicas e inter-harmônicas de tensão e corrente permitem (i) diferenciar estatisticamente condições mecânicas de um sistema trifásico isoladas de qualquer interferência elétrica (RQ1), e (ii) desagregar duas cargas elétricas operando simultaneamente a partir apenas da assinatura combinada (RQ2, NILM). Um pipeline reprodutível de 13 módulos foi construído para importar, validar, organizar, normalizar e analisar os dados, culminando em modelos estatísticos, de aprendizado de máquina clássico e de redes neurais recorrentes. Para RQ1, 606 canais harmônicos e 612 inter-harmônicos foram testados (ANOVA, correção FDR) sobre as 6 condições mecânicas puras da base; 97,0% e 99,3%, respectivamente, permaneceram significativos após correção, com tamanhos de efeito (η^2) de até 0,95 nos componentes mais sensíveis. Um achado central: nas falhas mecânicas a tensão desempenha papel proeminente (5 dos 15 canais mais importantes por SHAP), padrão que se inverte nas falhas elétricas (corrente domina, 1 em 15). Um classificador de 6 classes atingiu 80,9% de acurácia isolando apenas defeitos mecânicos, contra 92,3% no problema de 17 classes com defeitos elétricos incluídos. Para RQ2, a desagregação supervisionada (regressão multi-saída, validação leave-one-condition-out) recuperou parcialmente a assinatura da fonte elétrica em canais individuais (R^2 até 0,214, predominantemente inter-harmônicos), com uma ressalva estrutural relevante detalhada na Seção 4.4. Os resultados sustentam RQ1 como contribuição

consolidada; RQ2 é tratada como estudo de viabilidade dado n=4 condições combinadas disponíveis.

1 Introdução e objetivos
2 Materiais e métodos
3 Construção do sistema
4 Resultados
5 Discussão
6 Limitações
7 Conclusão

---

1 Introdução e objetivos

Sistemas trifásicos com cargas não-lineares (retificadores) e máquinas rotativas produzem, além da componente fundamental, um espectro de harmônicas e inter-harmônicas de tensão e corrente. A hipótese de trabalho é que esse espectro carrega informação diagnóstica tanto sobre o estado mecânico da máquina quanto sobre a composição das cargas elétricas conectadas. Duas perguntas de pesquisa orientam a análise:

- **RQ1** — Existe relação estatisticamente significativa entre harmônicas/inter-harmônicas e falhas mecânicas (desbalanceamento, desalinhamento), isolando qualquer influência elétrica? Quais componentes espectrais são mais sensíveis?
- **RQ2** — Com duas cargas elétricas operando simultaneamente no mesmo ponto de acoplamento, é possível desagregá-las (NILM) usando exclusivamente a assinatura espectral?

---

2 Materiais e métodos

2.1 Base de dados

Duas planilhas (HARMÔNICAS: 672 colunas; INTERHARMÔNICAS: 626 colunas), 19.501 aquisições cada, 17 condições experimentais. Cada planilha registra harmônicas/inter-harmônicas de ordem 1–50 (avg/max), tensão e corrente, três fases, além de THD/THDo/THDe/THD3, K-Factor e TID-F. As duas planilhas são séries temporais independentes do mesmo ensaio (timestamps não

coincidentes), pareadas por rótulo e proximidade temporal quando necessário (`organize.join.nearest_timestamp_join`).

2.2 Taxonomia experimental

Os 17 rótulos foram particionados em três categorias mutuamente exclusivas (`labels.taxonomy`), condição necessária para isolar RQ1 de interferência elétrica:

Tabela 1. Taxonomia experimental — categoria, papel na pesquisa e volume amostral.

CATEGORIA	N RÓTULOS	N AMOSTRAS	PAPEL
Mecânica pura	6	8.814	RQ1 — sensibilidade estatística isolada
Elétrica pura	7	4.580	Fonte elétrica de referência para RQ2
Combinada (máquina + elétrica)	4	6.107	RQ2 — desagregação supervisionada
Total	**17**	**19.501**	**—**

A classificação "mecânica pura" dos rótulos com sufixo "RET N PARAF" foi confirmada empiricamente (perfil harmônico estatisticamente indistinguível do baseline saudável, discrepante do perfil das condições com retificador conectado) — ver ressalva na Seção 6.

2.3 Protocolo estatístico (RQ1)

Para cada canal espectral (domínio × família × variável × fase × ordem × estatística), aplicou-se ANOVA de um fator entre as 6 condições mecânicas (`stats.group_tests.sweep_channels`), seguida de correção de Benjamini-Hochberg (FDR, α=0,05) sobre o conjunto completo de canais testados simultaneamente. Como tamanho de efeito multi-grupo, calculou-se η^2 (proporção de variância explicada pela condição, `sensitivity.effect_size.eta_squared`); para contrastes par-a-par (cada falha vs. baseline saudável), Cliff's delta não-paramétrico. Um classificador multi-classe restrito às condições mecânicas, com importância de atributos via SHAP e permutation importance, serviu de validação cruzada independente do ranking estatístico.

2.4 Modelos de aprendizado de máquina e redes neurais

Seis modelos clássicos (Random Forest, XGBoost, SVM, MLP, kNN, Regressão Logística) foram comparados automaticamente sob divisão treino/teste estratificada (70/30) para classificação de condição. Seis arquiteturas de redes

neurais recorrentes/atencionais (SimpleRNN, LSTM, GRU, BiLSTM, CNN+LSTM, Transformer temporal) foram treinadas sobre janelas de 8 aquisições consecutivas (`deep_learning.windowing`), com busca aleatória de hiperparâmetros disponível (`deep_learning.tuning.random_search`). Para desagregação (RQ2), regressão multi-saída (`RandomForestRegressor` via `MultiOutputRegressor`) mapeia a assinatura combinada às assinaturas médias das duas fontes puras.

2.5 Métricas

Classificação: acurácia e F1-macro. Estatística: p-valor bruto e ajustado (FDR), η^2, Cliff's delta. Regressão/NILM: MAE e R^2 por canal, calculado sobre previsões *out-of-fold* agrupadas das 4 dobras de validação (justificativa na Seção 4.4). Previsão sequencial: MSE/MAE normalizados e correlação entre valor real e previsto.

---

3 Construção do sistema

O pipeline (`harmonic_signatures`, Python 3.11) é organizado em 13 módulos com dependência estritamente unidirecional, cobertos por 107 testes automatizados (pytest):

Tabela 2. Módulos do pipeline, por fase.

FASE	MÓDULOS
Fundação	`schema` · `io` · `labels` · `validation` · `organize` · `normalize`
Análise	`visualization` · `stats` · `sensitivity` · `features`
Modelagem	`models` · `deep_learning` · `disaggregation` · `prediction`

Duas correções de engenharia relevantes para a validade dos resultados reportados: (1) as funções de varredura estatística (`sweep_channels`, rankings de efeito) inicialmente refiltravam o DataFrame completo por canal — O(n_canais × n_linhas), 339s para 666 canais — substituídas por agrupamento único (`groupby`), reduzindo para 1,7s (~200×), o que tornou viável testar todas as famílias espectrais em vez de um subconjunto; (2) a categorização de colunas do dataset combinado por sufixo `_harm` / `_inter` capturava apenas o bloco de colunas duplicadas entre planilhas (Seção 4.1), não as colunas genuínas — corrigida para categorização por família espectral (`features.selection.parse_feature_key`).

4 Resultados

4.1 Validação e qualidade da base de dados

Sem valores ausentes nas 19.501×2 aquisições; 0 linhas duplicadas; 4 registros com `Status` inválido (0,02%, planilha HARMÔNICAS). Percentual de zeros cresce com a ordem harmônica, atingindo ~57% em H46 (piso de ruído do analisador) — relevante para seleção de atributos em ordens elevadas.

Um achado de validação com impacto direto na Seção 4.4: as colunas `H00` – `H50 max` aparecem com nome idêntico nas duas planilhas. A comparação par-a-par (pareamento por rótulo + timestamp mais próximo) mostrou **85,81% de divergência** entre os valores (306 canais, 5.967.306 pares comparados, diferença absoluta máxima de 136,97 pontos percentuais) — não são duplicatas, mas fontes de dado distintas mantidas como *features* separadas (sufixos `_harm` / `_inter`).

4.2 Etapa 1 — Sensibilidade a falhas mecânicas (RQ1)

Tabela 3. Resultado do teste ANOVA por domínio espectral, 6 condições mecânicas, α=0,05 (FDR).

DOMÍNIO	CANAIS TESTADOS	SIGNIFICATIVOS (FDR)	%	H² MÁX.
Harmônicas (H)	606	588	97,0%	0,863
Inter-harmônicas (IH)	612	608	99,3%	0,953

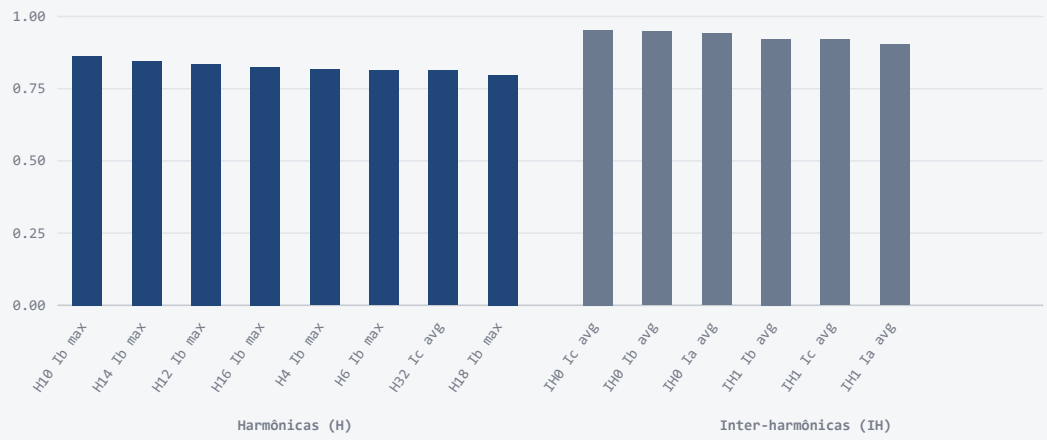


Figura 1. Top 8 canais por η² em cada domínio espectral (6 condições mecânicas). IH00–IH01 de corrente concentram os maiores tamanhos de efeito observados em todo o levantamento.

Contrastes par-a-par (Cliff's delta, cada condição vs. baseline saudável) revelam heterogeneidade entre tipos de falha: desalinhamento separa-se do baseline predominantemente em canais de **tensão** (H5 Vb avg/max, δ=1,000; H21 Vb avg, δ=−0,9999), enquanto desbalanceamento (RET 6 PARAF) separa-se em **corrente** de ordem 9 (δ=0,816) e tensão de ordem 27 (δ=−0,798) — evidência de que diferentes modos de falha mecânica produzem assinaturas espectrais qualitativamente distintas, não apenas graus diferentes da mesma assinatura.

Tabela 4. Classificador de condição mecânica (6 classes, 40 atributos selecionados, split 70/30).

MODELO	ACURÁCIA	F1-MACRO
SVM	**80,9%**	**0,806**
Regressão Logística	80,4%	0,801
kNN	74,5%	0,744
MLP	74,0%	0,735
Random Forest	72,6%	0,723
XGBoost	72,6%	0,722

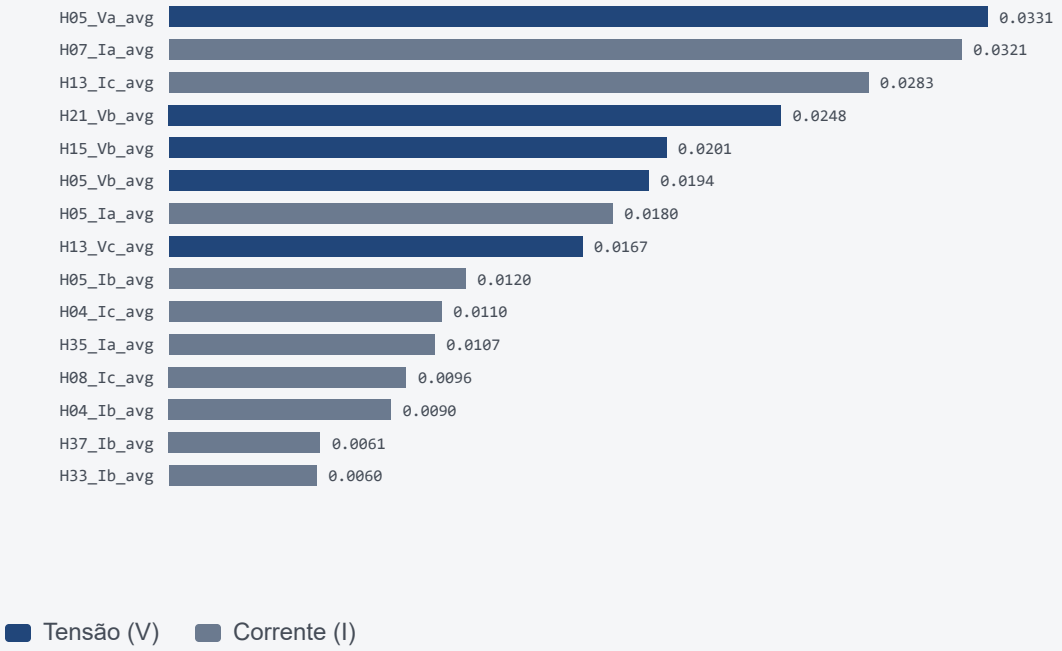


Figura 2. Importância SHAP (Random Forest, condições mecânicas) — 15 atributos mais relevantes. H05_Va_avg (tensão) lidera; 5 dos 15 principais atributos são de tensão, contra 1 em 15 no problema de 17 classes (Seção 4.3), consistente com o padrão de inversão discutido na Seção 5.

4.3 Classificação geral e comparação de modelos (17 classes)

Tabela 5. Modelos clássicos, 17 classes (mecânica + elétrica + combinada), 40 atributos selecionados.

MODELO	ACURÁCIA	F1-MACRO
SVM	**92,3%**	**0,939**
Regressão Logística	92,1%	0,937
MLP	92,0%	0,926
kNN	89,1%	0,914
Random Forest	87,3%	0,900
XGBoost	87,3%	0,899

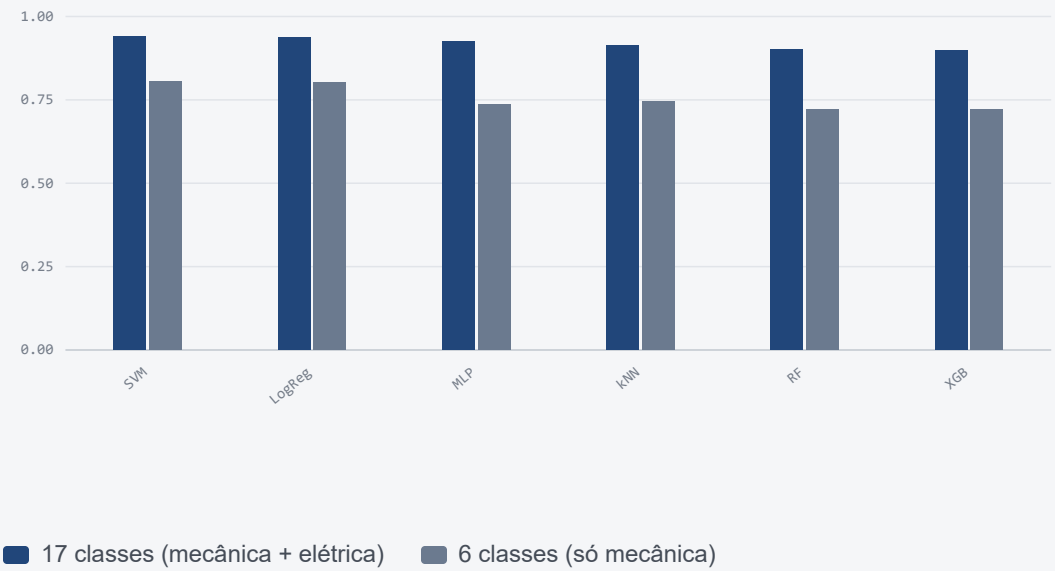


Figura 3. Acurácia de classificação (F1-macro) comparando o problema de 17 classes (mecânica+elétrica) com o subconjunto de 6 classes mecânicas puras, por modelo. A queda de ~13 p.p. em SVM/LogReg quantifica a maior sutileza da assinatura mecânica isolada.

Tabela 6. Arquiteturas de rede neural com contexto temporal (janela de 8 aquisições, 20 atributos, 17 classes).

ARQUITETURA	ACURÁCIA (VAL.)	PERDA (VAL.)
Transformer temporal	**85,7%**	**0,314**
CNN + LSTM	83,4%	0,397
BiLSTM	82,6%	0,393
LSTM	81,4%	0,467
GRU	80,6%	0,499
SimpleRNN	78,3%	0,530

Baseline rápido (6–8 épocas, sem ajuste extensivo de hiperparâmetros); nenhuma arquitetura recorrente supera os modelos clássicos sem contexto temporal neste regime de treinamento — ver discussão na Seção 5.

4.4 Etapa 2 — Desagregação de cargas / NILM (RQ2)

Das 984 colunas candidatas (666 harmônicas + 318 inter-harmônicas), 60 foram selecionadas por F-score ANOVA com eliminação de redundância por correlação (limiar 0,95): 27 harmônicas, 27 inter-harmônicas, 2 DC, 2 THD3, 2 THDe — distribuição balanceada entre domínios. Conjunto supervisionado: 6.107 amostras, 4 condições combinadas.

RESSALVA METODOLÓGICA

A validação *leave-one-condition-out* produz, por desenho, exatamente uma condição de teste por dobra — logo o alvo (assinatura da máquina OU da fonte elétrica) é **constante** dentro de cada dobra. Nessa condição, o R^2 do scikit-learn recai no caso especial de variância nula (0,0 ou 1,0 por definição, não uma medida de ajuste real) para os **dois** alvos — não apenas para "máquina", como um relatório preliminar desta pesquisa havia indicado. O MAE permanece válido (não depende de variância do alvo). A métrica com poder de generalização real é o R^2 por canal calculado sobre as previsões das 4 dobras agrupadas antes da pontuação (`disaggregation.model.per_channel_r2`), reportada abaixo.

Tabela 7. MAE por dobra (`evaluate_disaggregation`) — métrica não-degenerada desta função.

CONDIÇÃO RETIDA (TESTE)	MAE — MÁQUINA	MAE — FONTE ELÉTRICA
+ (−DIODO 2)	0,000	3,009
+ (−DIODO 3)	0,000	1,203
+ (−DIODO 6)	0,000	1,214
+ RETIFICADOR COMPLETO	0,000	3,267

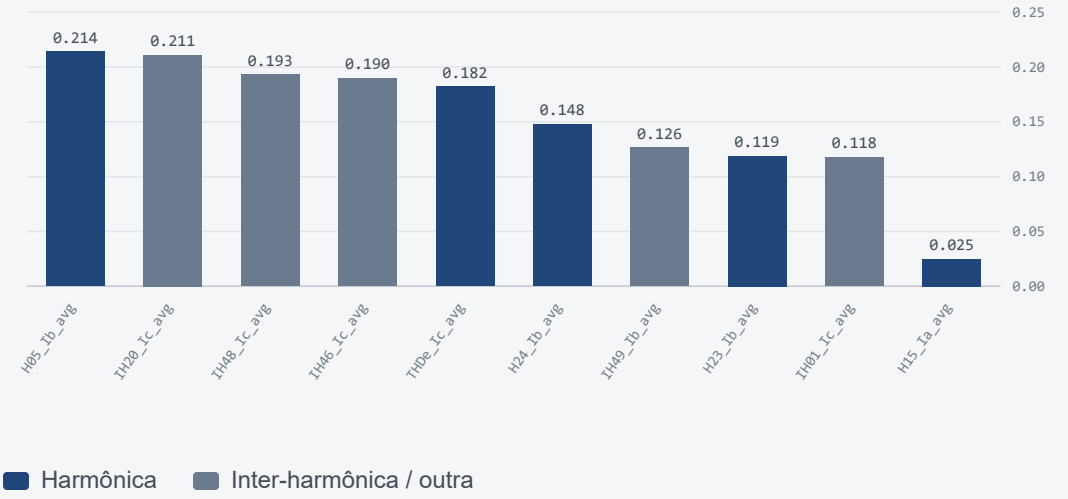


Figura 4. R^2 por canal (previsões agrupadas das 4 dobras), alvo = assinatura da fonte elétrica, 10 melhores de 60 canais. Inter-harmônicas ocupam 3 das 4 primeiras posições; entre os 20 melhores canais, 13 são inter-harmônicos e 7 harmônicos.

Dos 60 canais avaliados, 45 (75%) apresentam R^2 negativo (pior que prever a média) — a desagregação é seletiva por canal, não uniforme.

4.5 Previsão da assinatura futura

Um modelo BiLSTM, dado uma janela de 8 aquisições, previu o valor de H02_Ia_avg um passo à frente com MSE normalizado de 0,0475, MAE normalizado de 0,104 e correlação de 0,996 entre valor real e previsto no conjunto de validação — evidência de que a dinâmica de curto prazo da assinatura é aprendível, distinta da predição de tempo-até-falha (Seção 6).

---

5 Discussão

O padrão de inversão tensão/corrente entre falhas elétricas e mecânicas (Seções 4.2–4.3) é fisicamente coerente: o defeito elétrico está no caminho de corrente (retificador/diodo), enquanto desalinhamento e desbalanceamento afetam o entreferro e a força eletromotriz induzida, refletindo-se mais na tensão. Essa coerência com a teoria de máquinas elétricas é um argumento de validade externa além do desempenho puramente estatístico dos modelos.

Com ~1.400+ amostras por condição mecânica, o poder estatístico é elevado o suficiente para que 97–99% dos canais atinjam significância após correção FDR — por isso a Seção 4.2 apoia suas conclusões em η^2 e Cliff's delta, não no p-valor isoladamente, e cruza esse ranking com a importância SHAP de um classificador independente (triangulação metodológica).

Em RQ2, o predomínio de canais inter-harmônicos entre os melhor desagregados (13 de 20) é contraintuitivo frente à literatura de NILM, tradicionalmente concentrada em harmônicas — resultado a aprofundar com mais dados antes de generalizar.

---

6 Limitações

- **Tempo até a falha (RUL) não é suportado** pela base atual: cada rótulo é uma sessão estacionária de ~4–6h com a condição já configurada desde o início, sem trajetória contínua de degradação com evento de falha registrado.
- **RQ2 com n=4** condições combinadas — resultados da Seção 4.4 são um estudo de viabilidade, não validação estatisticamente robusta.
- **Divisão única treino/teste** nas Tabelas 4–5 (sem validação cruzada k-fold) — os números não têm intervalo de confiança associado.

- **Taxonomia "RET N PARAF"** (Tabela 1) inferida por similaridade espectral com o baseline e confirmada verbalmente com o responsável pelo ensaio — recomenda-se checagem contra o protocolo/caderno de laboratório original antes de uso como fato citável.
- Todas as condições foram registradas em uma única bancada/sessão por rótulo — sem replicação independente (dia diferente, outra unidade motora) para avaliar validade externa.

---

7 Conclusão

SUSTENTADO PELOS DADOS

- RQ1: sensibilidade estatística e por modelo, com tamanhos de efeito grandes (η^2 até 0,95) e coerência física (inversão tensão/corrente).
- Diagnóstico de 17 condições com 92,3% de acurácia/0,939 F1-macro usando 40 atributos.
- Descobertas de qualidade de dado (H-max, degenerescência do R^2 em NILM) identificadas e corrigidas no próprio pipeline, não apenas relatadas.

REQUER TRABALHO ADICIONAL

- RQ2: evidência real mas parcial (R^2 até 0,214 por canal); necessita mais condições combinadas para conclusão estatisticamente robusta.
- Validação cruzada k-fold para intervalos de confiança nas Tabelas 4–5.
- Confirmação documental da taxonomia "RET N PARAF" junto ao protocolo experimental.

RQ1 está, nesta avaliação, pronta para compor uma seção de artigo com revisão editorial; RQ2 configura um resultado preliminar promissor que justifica coleta adicional de dados antes de submissão.

Relatório gerado a partir de execuções reais do pipeline `harmonic_signatures` (notebooks 01–10, 107 testes pytest). Metodologia completa em

`docs/metodologia_cientifica.md`. Todos os números refletem saídas registradas dos notebooks executados nesta pesquisa.